

UNIVERSIDAD DEL VALLE DE GUATEMALA

Data Science

Sección 10

Ing. Mario Barrientos



PROYECTO No.2

MITSUI&CO. Commodity Prediction Challenge

Michelle Angel de María Mejía Villela, 22596

Silvia Alejandra Illescas Fernández, 22376

Pablo Sebastián Herrera Barbales, 21227

Jose Emilio Reyes Paniagua, 22674

Contenido

1. Introducción	3
2. Objetivos	3
3. Marco Teórico	4
Predicción de Precios de Commodities:	4
Modelos de Machine Learning:	4
Random Forest:	4
XGBoost:	4
GRU (Gated Recurrent Unit)	4
4. Metodología	5
1. Preprocesamiento de los Datos	5
2. Selección de los Modelos	5
3. División del Conjunto de Datos	6
4. Ingeniería de Características	6
5. Entrenamiento de los Modelos	6
6. Evaluación y Selección del Modelo	7
7. Desarrollo de la Aplicación	7
8. Herramientas y Recursos Computacionales	8
5. Resultados y Análisis de Resultados	8
1. Análisis Exploratorio de Datos (EDA)	8
2. Resultados de los Modelos	12
3. Visualizaciones de Predicción y Comportamiento de los Modelos	15
4. Interpretación Global de los Resultados	15
6. Conclusiones	16
7. Referencias	17

1. Introducción

En este proyecto, se abordó la predicción de los precios de commodities, productos básicos como el oro, petróleo, cobre y otros materiales de gran demanda, que juegan un papel crucial en las economías globales. La predicción precisa de estos precios es fundamental para la toma de decisiones en la planificación estratégica, la gestión de riesgos y la optimización de recursos en sectores económicos clave.

Los precios de los commodities son altamente volátiles y están sujetos a diversos factores externos como cambios en los mercados financieros, fluctuaciones en la oferta y demanda, y condiciones climáticas. Por tanto, la aplicación de técnicas de Machine Learning para la predicción de estos precios se vuelve una herramienta poderosa para anticipar estos cambios y facilitar la toma de decisiones.

En este proyecto, se entrenaron y evaluaron tres modelos de Machine Learning: Random Forest, XGBoost y GRU, con el objetivo de analizar su efectividad en la predicción de los precios de commodities y comparar sus desempeños.

2. Objetivos

Objetivo General: Desarrollar y evaluar modelos predictivos para anticipar los precios de commodities utilizando Machine Learning.

Objetivos Específicos:

- Implementar y entrenar los modelos Random Forest, XGBoost, y GRU.
- Realizar un análisis exploratorio de los datos para entender las relaciones entre las variables.
- Comparar el rendimiento de los modelos usando métricas como RMSE (Root Mean Squared Error) y MAE (Mean Absolute Error).
- Crear una aplicación interactiva utilizando Streamlit para mostrar las predicciones y el análisis exploratorio de los datos.

3. Marco Teórico

Predicción de Precios de Commodities:

Los commodities son bienes básicos que se producen en grandes cantidades y se comercializan globalmente. Estos incluyen productos como oro, petróleo, soja, trigo y otros. La predicción de sus precios es especialmente desafiante debido a los factores económicos, políticos y climáticos que afectan su valor. Modelar estos precios con precisión es fundamental para diversas industrias que dependen de estas materias primas.

Modelos de Machine Learning:

Random Forest: Es un modelo de ensemble learning basado en múltiples árboles de decisión. Random Forest es eficaz para capturar relaciones no lineales en los datos y es resistente al sobreajuste. Es un modelo sencillo pero robusto, capaz de manejar grandes volúmenes de datos.

XGBoost: Es una técnica de boosting que combina varios modelos débiles (como árboles de decisión) para formar un modelo fuerte. XGBoost es conocido por su eficiencia en tareas de predicción y su habilidad para manejar datos grandes y complejos. Es ampliamente utilizado debido a su alto rendimiento.

GRU (Gated Recurrent Unit): Es un tipo de red neuronal recurrente diseñada para manejar datos secuenciales. Utiliza compuertas que controlan qué información actualizar y cuál mantener, permitiendo capturar patrones temporales de forma eficiente. En este proyecto se empleó para modelar la dinámica temporal de los precios de los commodities.

4. Metodología

1. Preprocesamiento de los Datos

El conjunto de datos proporcionado para el reto de Commodity Prediction fue sometido a un proceso de limpieza y transformación con el objetivo de preparar las series temporales para el modelado.

Las actividades realizadas incluyeron:

1. Revisión y eliminación de valores faltantes, empleando imputación conservadora cuando correspondía y eliminación de observaciones corruptas en casos aislados.
2. Detección y tratamiento de outliers, utilizando estadísticas robustas (como IQR) y visualizaciones preliminares.
3. Normalización mediante StandardScaler, para asegurar que todas las variables compartieran una escala comparable, requisito clave para modelos basados en gradientes (XGBoost) y redes neuronales (GRU).
4. Construcción de ventanas temporales, generando secuencias del tipo lookback–forecast horizon para alimentar la GRU.
5. Separación del conjunto de datos en entrenamiento, validación y prueba, garantizando que el orden temporal no se viera alterado.

2. Selección de los Modelos

1. Random Forest:
Seleccionado por su capacidad para manejar relaciones no lineales, robustez ante ruido y excelente desempeño base para comparación general. Al no requerir normalización estricta ni tener alta sensibilidad a outliers, proporcionó un punto de referencia claro.
2. XGBoost:
Elegido por su eficiencia computacional, velocidad de entrenamiento y capacidad de regularización avanzada. Este modelo suele destacar en competencias de

Kaggle debido a su capacidad de capturar interacciones complejas entre variables.

3. GRU (Gated Recurrent Unit):

Modelo profundo diseñado específicamente para capturar dependencias temporales. Al tratarse de una serie temporal multivariante, la GRU permitió modelar dinámicas a mediano y largo plazo utilizando compuertas que controlan qué información mantener o actualizar.

3. División del Conjunto de Datos

Con base en la naturaleza temporal de los datos, se utilizó una división time-aware, es decir, sin mezclar valores futuros en el entrenamiento:

1. Entrenamiento: 70% de la serie temporal inicial.
2. Validación: 15%, inmediatamente consecutivo.
3. Prueba (Backtest): 15% restante, evaluado estrictamente de manera secuencial.

4. Ingeniería de Características

Para mejorar el desempeño de los modelos, se generaron variables derivadas:

1. Retornos porcentuales
2. Promedios móviles (SMA)
3. Tendencia mes a mes y semana a semana
4. Desviaciones típicas móviles (volatilidad)
5. Lag features para distintos horizontes

No todas estas fueron utilizadas por todos los modelos; las GRU trabajaron con secuencias normalizadas completas, mientras que Random Forest y XGBoost se beneficiaron de variables agregadas.

5. Entrenamiento de los Modelos

Cada modelo fue entrenado así:

Random Forest

1. Número de árboles ajustado entre 100–500.
2. Profundidad limitada para evitar sobreajuste.
3. Entrenado sobre características tabulares derivadas.

XGBoost

1. Se realizaron ajustes de hiperparámetros como: eta, max_depth, subsample, colsample_bytree y n_estimators.
2. Entrenado con early stopping para evitar sobreajuste.

GRU

1. Arquitectura definida con capas GRU de 32–64 unidades.
2. Dropout y regularización aplicados para evitar overfitting.
3. Entrenamiento mediante Adam y función de pérdida MSE.
4. Se entrenó por épocas con monitoreo de pérdida de validación.

6. Evaluación y Selección del Modelo

Se emplearon métricas estándar para regresión en series temporales:

1. RMSE (Root Mean Squared Error): Evalúa la magnitud promedio del error cuadrático.
2. MAE (Mean Absolute Error): Evalúa la distancia promedio entre la predicción y el valor real.

Estas métricas fueron calculadas en dos escenarios:

1. Validación: durante el entrenamiento.
2. Backtesting H-pasos: predicción sobre los últimos valores reales.

Cada modelo fue evaluado individualmente y posteriormente comparado entre sí, para determinar el mejor modelo en este escenario.

7. Desarrollo de la Aplicación

Posteriormente a los entrenamientos y desempeños de los modelos, desarrollamos una aplicación web con Dash que permite:

1. Navegar las variables del dataset luego del preprocesamiento.
2. Mostrar EDA completo y comparativo por commodity.
3. Visualizar métricas y performance por modelo (GRU, RF, XGBoost).
4. Permitir ocultar/mostrar capas gráficas.
5. Evaluar nuevos datos ingresados por el usuario.
6. Presentar las predicciones de los tres modelos simultáneamente.

La paleta de colores fue seleccionada siguiendo principios de contraste adecuado y consistencia visual.

8. Herramientas y Recursos Computacionales

Lenguaje: Python 3.11

Bibliotecas principales:

1. Pandas, NumPy para procesamiento
2. Scikit-Learn para Random Forest y preprocesamiento
3. XGBoost para boosting
4. TensorFlow/Keras para GRU
5. Plotly + Dash para visualizaciones y dashboard

5. Resultados y Análisis de Resultados


1. Análisis Exploratorio de Datos (EDA)

Antes del entrenamiento de los modelos, se realizó un análisis exploratorio profundo — visualizado en el dashboard— con el objetivo de comprender la estructura y comportamiento de las series temporales de los distintos commodities.

1.1 Series temporales globales: las series temporales mostraron comportamientos heterogéneos:

- gold presentó la variabilidad más alta y una tendencia ascendente clara en el tiempo.
- energy mostró fluctuaciones amplias y picos pronunciados, indicando alta volatilidad.
- rates, credit y financials se comportaron de forma más estable, con valores dentro de rangos moderados.
- asia_equity y credit_emerging mostraron patrones más suaves, con ciclos visibles.


Esto es importante porque modelos como Random Forest y XGBoost manejan bien relaciones no lineales, mientras que GRU es más sensible a series extremadamente volátiles.



1.2 Boxplots globales: los boxplots permitieron identificar la dispersión y posible presencia de outliers:

- energy presenta el mayor rango intercuartílico y la mayor cantidad de valores extremos.
- gold muestra varios outliers altos, reforzando su volatilidad.
- materials, credit y rates poseen cajas compactas, indicando estabilidad.


Esto explica por qué los modelos basados en árboles (RF/XGBoost) tuvieron ventaja:
No se ven tan afectados por outliers como una red neuronal recurrente.



1.3 Histogramas globales: los histogramas evidenciaron distribuciones multimodales en:


- financials, con al menos dos modos fuertes.
- energy, mostrando valores muy dispersos y asimetría marcada.
- rates, más concentrado alrededor de un único rango.

Los modelos pueden experimentar dificultades con distribuciones multimodales si no se incluye suficiente información temporal, lo que también puede afectar el desempeño de GRU.



1.4 Correlaciones: la matriz de correlación mostró asociaciones moderadas entre:

- rates ↔ credit
- financials ↔ asia_equity
- gold muy débilmente correlacionado con el resto




2. Resultados de los Modelos


Los modelos fueron evaluados utilizando RMSE y MAE sobre el conjunto de prueba (backtest).

2.1 Métricas obtenidas


GRU



BOOSTING: logró capturar las dinámicas no lineales entre las variables.



RANDOM FOREST: también alcanzó resultados competitivos, confirmando su robustez en relaciones complejas, aunque sin la fineza del boosting.



3. Visualizaciones de Predicción y Comportamiento de los Modelos

En el dashboard se incluyeron visualizaciones interactivas que permitieron analizar visualmente el rendimiento de los modelos:

3.1 Curvas de entrenamiento vs. validación

Los modelos Random Forest y XGBoost mostraron curvas estables sin signos fuertes de sobreajuste.

La GRU presentó mayor dispersión, indicando dificultad para converger de manera uniforme.

3.2 Backtest (predicción vs. real)

Las gráficas revelaron:

- XGBoost sigue el comportamiento real con menor desviación, especialmente en commodities estables.
- Random Forest muestra ligeras oscilaciones adicionales pero mantiene coherencia general.
- GRU acierta la tendencia general pero tiene más variabilidad, especialmente alrededor de los picos.

4. Interpretación Global de los Resultados

Podemos generalizar, los modelos basados en árboles manejaron mejor la variabilidad cruzada entre commodities, probablemente porque capturan no linealidades sin necesidad de estructuras temporales altamente complejas.

La GRU podría mejorar con ventanas más largas, más unidades o mayor regularización, pero para este problema específico los métodos tabulares resultaron más efectivos.

El análisis exploratorio mostró patrones y distribución de valores que explican en gran parte los resultados obtenidos.

La aplicación desarrollada permite validar estas conclusiones mediante interacción directa con las series, métricas y visualizaciones.

6. Conclusiones

El proyecto cumplió exitosamente con los objetivos planteados: se realizó un análisis exploratorio completo de las series temporales, se prepararon los datos adecuadamente y se entrenaron tres modelos predictivos (Random Forest, XGBoost y GRU). El dashboard permitió integrar estos resultados de forma clara e interactiva.

En términos de desempeño, XGBoost fue el modelo más efectivo, alcanzando los valores más bajos de RMSE y MAE gracias a su capacidad para capturar relaciones no lineales y manejar variaciones complejas. Random Forest mostró un rendimiento estable y competitivo, mientras que GRU, aunque adecuada para series temporales, obtuvo un desempeño ligeramente inferior debido a la volatilidad presente en algunos commodities.

En conjunto, la metodología empleada y la implementación del dashboard permitieron analizar, comparar y visualizar el comportamiento de los modelos, demostrando la utilidad de combinar técnicas clásicas de machine learning con modelos de deep learning en el análisis de series financieras.

7. Referencias

- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32.
- Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *ACM SIGKDD*.
- Chen, Y., Wang, S., & Zhu, L. (2025). PREIG: Physics-informed and Reinforcement-driven Interpretable GRU for Commodity Forecasting. *arXiv preprint*.
- Chung, J., Gulcehre, C., Cho, K., & Bengio, Y. (2014). Gated Recurrent Neural Networks. *arXiv:1412.3555*.
- Hu, R., Liu, Z., & Fang, J. (2024). Extreme learning machine optimized with genetic algorithms for agricultural commodity price forecasting. *Neural Computing and Applications*, 36, 10721–10734.
- Kaggle. (2024). MITSUI & CO. Commodity Prediction Challenge – Dataset.