

mitsui & co. COMMODITY

Prediction Challenge

Proyecto 2

Michelle Mejía 22376

Emilio Reyes 22674

Silvia Illescas 22376

Pablo Herrera 21227

Introducción

PLANTEAMIENTO DEL PROBLEMA - PREDICCIÓN DE PRECIOS DE COMMODITIES









Los precios de los commodities son altamente volátiles por factores económicos, políticos y climáticos, anticiparlos es fundamental para las empresas e industrias que dependen de estas materias primas.

En este proyecto se realiza un análisis la predicción de precios de commodities como el oro, el petróleo y otros insumos esenciales utilizando modelos de Machine Learning.

NUESTRO OBJETIVO...

Desarrollar y evaluar modelos de Machine Learning para predecir los precios de commodities y apoyar la toma de decisiones en un entorno económico incierto.

Análisis Exploratorio



Modelos Utilizados

Se emplearon tres modelos para predecir los precios de commodities. Cada uno de ellos presenta características específicas que lo hacen adecuado para enfrentar el desafío de predecir precios en mercados altamente volátiles.

GRU

Modelo de **red neuronal recurrente** especialmente **adecuado para el análisis de series temporales**. Permite **capturar dependencias a corto y mediano plazo** en los precios de commodities, aprovechando la información histórica y secuencial de los datos.

Random Forest

Modelo basado en árboles de decisión que utiliza **múltiples árboles para generar predicciones más robustas**. Resulta eficaz para manejar relaciones no lineales y es ampliamente utilizado por su relativa facilidad de interpretación.

XgBoost

Técnica de boosting que combina varios modelos débiles (como árboles de decisión) para formar un modelo más fuerte. **Se emplea especialmente en problemas con grandes volúmenes de datos** y para mejorar la precisión de las predicciones.

GRU

RMSE validación

0.5544

MAE validación

0.4404


RMSE backtest H

0.9545


MAE backtest H

0.7948

GRU — Entrenamiento + Backtest (rates)



RF — Backtest H pasos (rates)



Ejemplo Commodities Rates (Tarifas de envío)

RANDOM FOREST

RMSE validación

0.4530

MAE validación

0.3625

RMSE backtest H

1.1750


MAE backtest H

1.0400

RF — Entrenamiento + Backtest (rates)



RF — Backtest H pasos (rates)



Ejemplo Commodities Rates (Tarifas de envío)

XgBoost

RMSE validación
0.4120

MAE validación
0.3279


RMSE backtest H
1.5312

MAE backtest H
1.3789

XGBoost — Entrenamiento + Backtest (rates)



XGBoost — Backtest H pasos (rates)



Ejemplo Commodities Rates (Tarifas de envío)

Discusión de Resultados

DA reveló comportamientos muy distintos entre commodities

- Gold y energy: alta volatilidad
- Rates y credit: series más estables

Esto refleja la naturaleza real del mercado, donde algunos activos son más sensibles a eventos económicos y otros mantienen comportamientos más previsibles.



Discusión de Resultados

Correlaciones moderadas entre algunas variables

Se observaron asociaciones claras, como $\text{financials} \leftrightarrow \text{asia_equity}$ y $\text{rates} \leftrightarrow \text{credit}$, lo que indica que algunas categorías se mueven de forma conjunta.

Este tipo de relaciones es clave para entender qué tan interconectados están los mercados y cómo ciertos shocks pueden propagarse entre distintos sectores.




Discusión de Resultados

XGBoost obtuvo el mejor desempeño general

Presentó los valores más bajos de RMSE y MAE, mostrando una predicción más precisa.

Su arquitectura de boosting permite capturar relaciones complejas entre variables y ajustarse mejor a patrones no lineales.

Esto lo convierte en el modelo más confiable para este tipo de series financieras.




Discusión de Resultados

A pesar de no ser tan preciso como XGBoost, mantuvo errores bajos y consistentes.


Es robusto ante ruido y valores atípicos, lo que lo hace ideal como modelo base y comparativo.

Su desempeño estable valida que las relaciones en los datos pueden modelarse efectivamente con técnicas de árboles.



Discusión de Resultados

La red GRU logró identificar la dirección general de las series, pero tuvo dificultades con picos y volatilidad. Esto se debe a que las series de commodities tienen cambios abruptos que afectan el aprendizaje secuencial.



Conclusiones

Los objetivos fueron cumplidos: se prepararon los datos, se analizaron las series, se entrenaron tres modelos y se creó un dashboard robusto.

XGBoost destacó como la mejor herramienta predictiva, Random Forest fue sólido y GRU aportó perspectiva temporal.

El proyecto demuestra que combinar análisis exploratorio, machine learning y visualización interactiva es altamente efectivo para comprender y predecir mercados financieros.



Referencias

Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32.

Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *ACM SIGKDD*.

Chen, Y., Wang, S., & Zhu, L. (2025). PREIG: Physics-informed and Reinforcement-driven Interpretable GRU for Commodity Forecasting. *arXiv preprint*.

Chung, J., Gulcehre, C., Cho, K., & Bengio, Y. (2014). Gated Recurrent Neural Networks. *arXiv:1412.3555*.

Hu, R., Liu, Z., & Fang, J. (2024). Extreme learning machine optimized with genetic algorithms for agricultural commodity price forecasting. *Neural Computing and Applications*, 36, 10721–10734.

Kaggle. (2024). MITSUI & CO. Commodity Prediction Challenge – Dataset.