



RESULTADOS INICIALES



PROYECTO 2

MITSUMI&CO. Commodity Prediction

**INTEGRANTES
DEL EQUIPO**

- Michelle Mejía
- Silvia Illescas
- Pablo Herrera
- Emilio Reyes



RECORDANDO EL PROBLEMA

- Los mercados de commodities presentan alta volatilidad.
- Factores: económicos, políticos, climáticos y logísticos.
- Esto dificulta:
 - La toma de decisiones.
 - La planificación estratégica.
 - La gestión de riesgos y recursos.
- Mitsui & Co. propone un reto para anticipar precios y analizar tendencias.



Commodities

Materias primas que se producen en grandes cantidades y se venden a nivel mundial (oro, plata, cobre, petróleo, café, trigo, maíz, azúcar, soya, divisas, metales industriales).



Modelo Predictivo De Precios Y Patrones de Commodities



Modelos Clásicos Utilizados

ARIMA, ARIMAX, Suavizado Exponencial.

- Limitación: No capturan bien relaciones no lineales.

Modelos de Machine Learning:

Random Forest: Para manejar datos complejos y no lineales.

XGBoost: Método de ensamblaje iterativo con corrección de errores.

Modelos de Deep Learning:

LSTM y GRU: Redes neuronales recurrentes que recuerdan la secuencialidad temporal.



Random Forest



¿Por qué elegirlo?











- Maneja relaciones no lineales.
- Requiere menos datos de entrenamiento.
- Eficiente para grandes volúmenes de datos



Resultados
Obtenidos

- Buen rendimiento para algunas columnas, especialmente LME_AH_Close y LME_ZS_Close.
- Errores en fluctuaciones extremas de precios.
- Posibles ajustes: Aumento de n_estimators, ajuste de max_depth y min_samples_split.







XGBOOST

Rendimiento en el sector de energía:


- Correlación de Spearman promedio: 0.377, indicando una relación moderada.
- RMSE: 0.026, lo que sugiere errores estables.




Observaciones Clave y Variables Relevantes

Las predicciones tienden a suavizar movimientos bruscos.

Variables relevantes: Materials, Financials, y Credit son claves para predecir precios de energía.





Las features más relevantes

Target	Feature 1	Feature 2	Feature 3
Energy	Materials_mean3	Financials_mean3	Materials_lag2
Gold	Rates_mean3	Credit_emerging_mean3	Credit_emergin_mean10
Materials	Financials_mean3	Asia_equity_mean3	Asia_equity_std5
Rates	Creditemerging_mean3	Credit_emerging_mean5	Gold_mean3
credit	Financials_mean3	Materials_mean3	Credit_emerging_mean3
Credit emerging	Materials_mean3	Energy_mean3	Credit_mean3
Asia equity	Materials_mean3	Financials_mean3	Materials_lag1
financials	Materials_mean3	Energy_lag1	Asia_equity_mean3



RED NEURONAL

LSTM (Long Short-Term Memory)



¿Por qué LSTM?


- Capaz de capturar dependencias temporales a largo plazo.
- Adecuado para series de tiempo con memoria a largo plazo.




Resultados Obtenidos

- Mejor rendimiento para algunos commodities comparado con Random Forest, aunque sigue presentando desafíos con volatilidad extrema.
- Ajustes: Reducción de unidades y épocas para mejorar el tiempo de entrenamiento.


=== Entrenando GRU para: rates ===
RMSE_ret = 0.004102, MAE_ret = 0.003287




=== Entrenando GRU para: financials ===
RMSE_ret = 0.019626, MAE_ret = 0.012765



=== Entrenando GRU para: energy ===
RMSE_ret = 0.021585, MAE_ret = 0.014729




=== Entrenando GRU para: credit_emerging ===
RMSE_ret = 0.004640, MAE_ret = 0.003411







=== Entrenando GRU para: asia_equity ===
RMSE_ret = 0.012717, MAE_ret = 0.009163




=== Entrenando GRU para: gold ===
RMSE_ret = 0.011088, MAE_ret = 0.008421



=== Entrenando GRU para: credit ===
RMSE_ret = 0.003512, MAE_ret = 0.002371



=== Entrenando GRU para: materials ===
RMSE_ret = 0.011345, MAE_ret = 0.007958



Conclusiones

- Random Forest sufrió dificultades con fluctuaciones de precios, pero es eficiente en general. Necesita ajustes finos en los hiperparámetros.
- A pesar de que XGBoost es un modelo poderoso, los resultados fueron moderadamente buenos en predicción de energía, con una suavización de movimientos bruscos.
- LSTM es bueno para capturar patrones temporales, pero presenta limitaciones con volatilidades grandes.



¡Muchas Gracias!

Referencias

Chen, Y., Wang, S., & Zhu, L. (2025). PREIG: Physics-informed and Reinforcement-driven Interpretable GRU for Commodity Forecasting. arXiv preprint arXiv:2507.21710. <https://arxiv.org/abs/2507.21710>

Herrera, M., Poggi, M., & Rojas, J. (2019). Machine learning approaches for energy price forecasting: Random forest and hybrid models. *Energies*, 12(14), 2685. <https://doi.org/10.3390/en12142685>

Hu, R., Liu, Z., & Fang, J. (2024). Extreme learning machine optimized with genetic algorithms for agricultural commodity price forecasting. *Neural Computing and Applications*, 36, 10721–10734. <https://doi.org/10.1007/s00521-024-09679-x>

Li, H., Sun, Y., & Zhou, Q. (2024). Hybrid VMD–EEMD–LSTM model for agricultural price forecasting. *Agriculture*, 14(1), 60. <https://doi.org/10.3390/agriculture14010060>

USDA. (2022). Commodity price forecasting using ARIMA and Monte Carlo simulation. U.S. Department of Agriculture, Economic Research Service.

Vairo, D., & Martínez, J. (2024). Neural network architectures for agricultural commodity price forecasting. *Applied Mathematical Sciences*, 18(5–8), 193–206. <https://www.m-hikari.com/ams/ams-2024/ams-5-8-2024/p/vairoAMS5-8-2024.pdf>

Wang, T., Zhang, Y., & Xu, H. (2023). Forecasting agricultural prices using hybrid SARIMA-LSTM models for global food security. *Sustainability*, 15(4), 2123. <https://doi.org/10.3390/su15042123>

World Bank. (2023). Commodity Market Outlook: Forecasting commodity prices with time series models. World Bank Group.

Zhang, L., & Liu, P. (2025). Volatility prediction of agricultural prices using hybrid LSTM-GARCH model. *Journal of Big Data*, 12(1), 59. <https://doi.org/10.1186/s40537-025-01131-8>

Zhao, Q., Huang, R., & Li, S. (2024). Deep temporal convolutional and Transformer-based models for commodity price prediction. *Financial Innovation*, 10(3), 211–229. <https://doi.org/10.1186/s40854-024-00637-z>

